

Ficha de Especificación Técnica — Dataset Reto Tech Sphere 2026

Reto: Agente de voz para seguimiento post-operatorio de pacientes

Autor: Gabriel Cepeda (comité académico) · con José Luis Salamanca y Juan Camilo Zapata

Fecha: 2026-07-14

Propósito de este documento: presentar al comité la estrategia técnica de generación del dataset del reto — herramientas, pipeline de generación, y manejo de la limitación de sesgo geográfico de Synthea.


1. Escenario de negocio


Los equipos participantes deben construir un agente de voz que realice **llamadas de seguimiento a pacientes en recuperación post-operatoria**, capaz de:

- Recolectar información de síntomas (dolor, fiebre, movilidad, herida, apetito, sueño).
- Clasificar el caso en  normal /  vigilar /  escalar a médico.
- Manejar conversación ambigua, ruidosa o con interlocutor equivocado sin fallar en la clasificación de seguridad.

El dataset debe permitir **evaluar objetivamente** estas tres capacidades — no solo proveer volumen de datos.

2. Arquitectura de generación del dataset






Herramientas evaluadas (2 alternativas por capa):

Capa	Alternativa A	Alternativa B	Decisión
Datos clínicos estructurados	Synthea (MITRE) — historias clínicas realistas, módulos post-operatorios	SDV (Synthetic Data Vault) — aprende distribución estadística de un esquema propio, más flexible en campos de seguimiento	Synthea como base clínica
Transcripciones de llamadas	SDialog — toolkit LLM-a-LLM con ejemplos de seguimiento clínico	Simulación dual-LLM manual — LLM-paciente + LLM-agente con perfil Synthea como contexto	Dual-LLM manual (más rápido de implementar, control total sobre el paciente simulado)

3. Limitación identificada: sesgo geográfico de Synthea

⚠ Synthea trae, por defecto, demografía, códigos postales, proveedores, nombres y costos calibrados con datos públicos de **EE. UU.**, y los módulos de enfermedad usan prevalencia/incidencia por género, raza y edad estadounidenses.



Resolución adoptada:

- Existe un repo comunitario [synthea-international](#), pero su cobertura es aproximada (ej. Europa reutiliza el perfil demográfico de Finlandia para todos los países) — **no hay perfil dedicado para Colombia.**
- Los **módulos de enfermedad/cirugía** se mantienen sin cambios: la progresión clínica post-operatoria no depende de la nacionalidad del paciente.
- La **capa demográfica/geográfica** (nombres, ciudades, direcciones, EPS) se reemplaza en post-proceso por datos colombianos genéricos, o se omite directamente si el reto no evalúa esa dimensión — evita presentar al comité un dataset con sesgo cultural no declarado.

4. Stack de implementación recomendado (Databricks)

Synthea es nativo en **Java**. Para extenderlo dentro de Databricks sin fricción de JVM, se evalúan 2 rutas:

Opción	Cómo se ve en Databricks	Decisión
Synthea original (Java)	Se corre el .jar como Job Task tipo JAR en un cluster (patrón oficial de Databricks — existe el solution accelerator "rwe-lakehouse" con notebooks 3-run-synthea-singlenode + 3-synthea-ingest); salida	Opción de respaldo si algún módulo clínico no está cubierto por PySynthea

Opción	Cómo se ve en Databricks	Decisión
	CSV/FHIR se ingiere a Delta con Autoloader	
<u>PySynthea</u> (reimplementación Python nativa, TietAI, mayo 2026)	<code>pip install</code> , corre directo en el notebook/cluster sin JVM, exporta a pandas/CSV/JSON/FHIR nativamente	Recomendada — se integra sin salir de Python/Spark con el resto del pipeline (adaptación Colombia, simulación dual-LLM, capas de ruido)

Databricks Cluster (single-
node, notebook)

PySynthea\nmódulos post-
operatorios

Post-proceso\nadaptación
Colombia\npandas/PySpark
UDF

Tabla
Delta\nperfiles_pacientes

Llamadas LLM\nModel
Serving / API
externa\nsimulación dual-
LLM







Tabla
Delta\ndialogos_capa1_limpia


UDF inyector de
ruido\nintensidad 1-5

Tabla
Delta\ndialogos_capa2_ruidosa

Notebook curado
manual\ncasos límite

Tabla
Delta\ndialogos_capa3_limite\nACL
restringido a comité





Por qué esta combinación:

- PySynthea evita editar módulos GMF en el DSL propio de Synthea (engorroso) — el ajuste "reemplazar capa demográfica por datos colombianos" se hace como transformación normal de DataFrame.
- Todo el pipeline (Synthea → diálogos → ruido → casos límite) escribe a **Delta/Unity Catalog** — versionado, linaje y control de acceso nativo para ocultar la Capa 3 al resto de participantes.
- Las llamadas LLM de la simulación dual-LLM se hacen vía **Databricks Model Serving** o API externa desde el mismo notebook, sin infraestructura adicional.

Riesgo a validar: PySynthea es muy reciente (mayo 2026) — confirmar en su repo/PyPI que cubre los módulos post-operatorios necesarios con la misma profundidad que Synthea original antes de comprometerse a esta ruta.

5. Mecanismo de "ensuciado" + casos límite

Capa	Contenido	Objetivo de evaluación
1 — Base limpia	Transcripción ideal + etiqueta ground-truth (●/●/●)	Referencia para medir degradación
2 — Ruidosa	Ruido STT, modismos regionales, respuestas ambiguas, contradicciones, información faltante, cambio de interlocutor — aplicado sobre la Capa 1, con mapeo guardado	Medir cuánto se degrada la clasificación por tipo específico de ruido
3 — Casos límite (oculta a participantes)	Alarma real inequívoca, falso positivo/paciente ansioso, solicitud de diagnóstico directo, PII sensible mezclada	Examen objetivo del comité — no se le entrega a los equipos

6. Entregables técnicos obligatorios (para el comité)

- ☐ Script de generación de perfiles Synthea (módulos post-operatorios seleccionados)
- ☐ Script de post-proceso de adaptación geográfica (Colombia)
- ☐ Script de simulación dual-LLM (prompts de paciente y agente documentados)
- ☐ Script inyector de ruido parametrizable (niveles 1-5)
- ☐ Set curado de casos límite (Capa 3) — versión oculta para el comité
- ☐ Documentación de mapeo Capa 1 → Capa 2 (para trazabilidad de la degradación)

7. Criterios de rechazo inmediato (a validar con la rúbrica del comité)

- Dataset sin distinción entre capas (todo mezclado, sin poder aislar el efecto del ruido).
- Casos límite no verificables o inconsistentes con protocolos clínicos reales.
- Ausencia de manejo explícito del sesgo geográfico de Synthea (dataset presentado como "colombiano" sin declarar el post-proceso).

Documento de apoyo para presentación ante el comité académico · Vault: Gabriel_SM · Ver seguimiento operativo en [Tech Sphere Challenge 2026](#)